



CIENCIA DE DATOS EN PRODUCCIÓN

ENTREGABLE 2 (15%)

Docente: Juan Sebastián Parra Sánchez

Estás participando para ser parte del equipo de Datos y Analítica de una empresa financiera, en donde hay una posición para Científico de Datos Junior.

Se te entrega una base de datos con información del crédito, el usuario de dicho crédito y el pago del mismo (si se hizo a tiempo o cayó en mora). Se quiere evaluar su capacidad para generar insights valiosos para la organización a partir de estos datos y, además, su capacidad para comunicarlos adecuadamente.

Le entregan el DataFrame pero no un diccionario de datos, por lo que debes hacer uso de tu creatividad, búsqueda en internet, etc para entender mejor el negocio y las variables que allí se tienen.

Este entregable consta de dos partes:

1. Carpeta en .zip ejecutable

Presentar en el repositorio esta estructura de carpetas:

PYTHON_ETL/

```
├── codigoproyecto-venv/      # Entorno virtual (puede excluirse)
├── etl_scripts/
|   └── src/
|       ├── desarrollo/
|       |   ├── __pycache__/  # Archivos compilados de Python
|       |   └── transformacion_eda.ipynb # Notebook de transformación y EDA
|       └── config.json       # Configuración del proyecto
|
├── Base_de_datos.csv        # Archivo fuente de datos
├── requirements.txt         # Dependencias del proyecto
├── .gitignore              # Exclusiones para Git
├── readme.md               # Documentación del proyecto
└── set_up.bat              # Script de configuración inicial
```

2. **Presentación de los principales insights encontrados (exposición de 15 minutos máximo). Es una presentación enfocada hacia un líder técnico y alguien de negocio.**

¿Qué debe tener el archivo transformacion_eda.ipynb?

1. **Carga de datos**
2. **Exploración inicial de datos**
 - 2.1 Descripción general de los datos. Caracterización de los datos: categóricos, numéricos, ordinales, nominales, dicotómicos, politómicos. Revisión de nulos.
 - 2.2 Unificar la forma como se representan los valores Nulos.
 - 2.3 Eliminación de variables irrelevantes.
 - 2.4 Convertir los datos en su tipo correcto (numéricos, categóricos, booleanos, fechas, etc) y corrección de los datos si es necesario, para cada columna tenga un tipo de dato uniforme.
3. **Exploración de datos y descripción (EDA)**

3.1 Análisis univariable.

Se recomienda hacer un describe() una vez se hayan ajustado los tipos de datos. Se recomienda para las variables numéricas: histograma para distribución, boxplot, tablas pivote.

Para las variables categóricas: countplot, tablas pivote, value_counts()

Descripción estadística (dependiendo del tipo de dato): por ejemplo para los numéricos: tendencia Central (media, mediana, moda, max, min, etc), medidas de dispersión (Rango, IQR, cuartiles, varianza, desviación estándar, skewness y kurtosis). Tipo de distribución (gaussiana, uniforme, logarítmica, etc.)

3.2 Análisis bivariable.

Se recomienda generar gráficos y tablas con respecto a la variable objetivo y comentar.

3.3 Análisis multivariable

Revisar relaciones entre variables. Se puede incluir un pairplot(), tablas cruzadas, matriz de correlación, gráficos de dispersión entre variables numéricas, gráficos utilizando el parámetro hue para las variables categóricas.

El análisis debe contener:

- * Compresión detallada de las características y el esquema de datos. Muchos comentarios, interpretaciones, análisis de lo que se encuentra.
- * Analice los datos para crear las reglas de validación de los datos que serán usadas en otra etapa del proyecto. Por ejemplo, rango de edades.
- * Para los proyectos de aprendizaje supervisado, identifique los atributos objetivo (target).
- * Identificar las transformaciones que tal vez se puedan aplicar.
- * Identificar atributos adicionales (derivados, calculados) que pueden ser útiles. (MUY IMPORTANTE Y DE GRAN VALOR)